

어종 분류를 위한 CNN의 적용

박진현¹ · 황광복² · 박희문³ · 최영규^{4*}

Application of CNN for Fish Species Classification

Jin-Hyun Park¹ · Kwang-Bok Hwang² · Hee-Mun Park³ · Young-Kiu Choi^{4*}

¹Professor, Dept. of Mechatronics Engineering, Kyeognam National Univ. of Science and Technology, Jinju 52725, Korea

²Ph.D. Student, Dept. of Mechatronics Engineering, Kyeognam National Univ. of Science and Technology, Jinju 52725, Korea

³Employee, British American Tobacco Korea, Sacheon, 52530, Korea

^{4*}Professor, Department of Electrical Engineering, Pusan National University, Pusan 46241, Korea

요 약

본 연구에서 외래어종 퇴치를 위한 시스템 개발에 앞서 물 안의 어류 이미지를 CNN으로 학습하여 어종을 분류하는 알고리즘을 제안하고자 한다. CNN 학습을 위한 원데이터(raw data)는 각 어종에 대해 직접 촬영한 영상을 사용하였으며, 어종 분류성능을 높이기 위해 영상 이미지의 개수를 늘린 데이터셋 1과 최대한 자연환경과 가까운 영상 이미지를 구현한 데이터셋 2를 구성하여 학습 및 테스트 데이터로 사용하였다.

4가지 CNN의 분류성능은 데이터셋 1에 대해 99.97%, 데이터셋 2에 대해 99.5% 이상을 나타내었으며, 특히 데이터셋 2를 사용하여 학습한 CNNs이 자연환경과 유사한 어류 이미지에 대해서도 만족할 만한 성능을 가짐을 확인하였다. 그리고 4가지 CNN 중 AlexNet이 성능에서도 만족스러운 결과를 도출하였으며, 수행시간과 학습시간 역시 가장 짧아 외래어종 퇴치를 위한 시스템 개발에 가장 적합한 구조임을 확인하였다.

ABSTRACT

In this study, before system development for the elimination of foreign fish species, we propose an algorithm to classify fish species by training fish images with CNN. The raw data for CNN learning were directly captured images for each species, Dataset 1 increases the number of images to improve the classification of fish species and Dataset 2 realizes images close to natural environment are constructed and used as training and test data.

The classification performance of four CNNs are over 99.97% for dataset 1 and 99.5% for dataset 2, in particular, we confirm that the learned CNN using Data Set 2 has satisfactory performance for fish images similar to the natural environment. And among four CNNs, AlexNet achieves satisfactory performance, and this has also the shortest execution time and training time, we confirm that it is the most suitable structure to develop the system for the elimination of foreign fish species.

키워드 : 컨볼루션 신경망, 어류 이미지, 어류 종, 알렉스넷, 분류

Key word : CNN(Convolutional Neural Network), Fish Image, Fish Species, AlexNet, Classification

Received 7 November 2018, Revised 26 November 2018, Accepted 10 December 2018

* Corresponding Author Young-Kiu Choi(ykichoi@pusan.ac.kr; Tel: +82-51-5102371)

Professor, Department of Electrical Engineering, Pusan National University, Pusan 46241, Korea

Open Access <http://doi.org/10.6109/jkiice.2019.23.1.39>

print ISSN: 2234-4772 online ISSN: 2288-4165

© This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License(<http://creativecommons.org/licenses/by-nc/3.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.
Copyright © The Korea Institute of Information and Communication Engineering.

I. 서 론

환경부는 2007년부터 생태계 교란 외래 생물 종에 대한 모니터링을 진행하고 있으며, 2011년부터는 외래종 16종에 대하여 매년 조사를 진행하고 있다. 특히 2010년 제10차 생물다양성협약 당사국 총회에서 생물 다양성 보전을 위한 목표 중 ‘침입 외래종 제거’를 발표함으로써 침입 외래종 제거에 관한 연구가 국내외에 활발히 진행되고 있다[1]. 특히 국내 내수면의 생태계 교란 생물로 외래어종인 큰입배스(large mouse bass)와 블루길(bluegill)은 국내 토종어류의 개체군 감소에 가장 중요한 요인으로 알려져 있다. 따라서 이러한 외래어종 퇴치를 위한 효율적이고 확실한 시스템 개발이 필요한 실정이다. 따라서 외래어종 퇴치를 위한 전체 시스템 개발에 앞서 물고기 어종 분류를 위한 시스템 개발이 선행되어야 한다.

수년 전부터 기계 학습(machine learning) 및 딥러닝(deep learning)에 관한 관심이 높아지고 있으며 특히 딥러닝은 기계 학습의 한 방법으로 컴퓨터가 직접 데이터로부터 스스로 학습하는 네트워크 모델로 직접 이미지, 텍스트 등을 분류하고 학습할 수 있다[2-4]. 이러한 발전은 빅데이터(big data)의 활용, 고성능 GPU(Graphic Processing Unit) 같은 하드웨어의 발전과 인식알고리즘의 개발 등에 힘입어 실용성 높은 기술로 발전되었으며, 다양한 형태의 미디어들이 증가하면서 딥러닝의 응용 분야들이 새롭게 창출되고 있다[2-6]. 그중 1990년도 후반 LeCun 교수에 의한 개발된 CNN(convolutional Neural Network)은 사람이나 동물의 시각처리 과정을 모방하여 역전파 학습알고리즘(back propagation learning algorithm)을 기반으로 영상 인식 분야에 성공적으로 적용함으로써 널리 사용되고 있다[2].

이러한 영상 인식 분야 중 물고기 종의 인식 분야에 성공적으로 적용한 사례도 있으나[7,8], 이는 물 안이 아닌 물 밖이나 배 위에서 촬영한 물고기 영상으로 어종을 분류하는 작업이 수행되었다. 그리고 자연환경에 서식하는 물고기의 분류작업은 같은 종의 물고기 데이터를 축적하기 어려워 학습 및 테스트에 많은 어려움이 따른다[9-11]. 또한, 일반적인 CNN은 ILSVRC(ImageNet Large Scale Visual Recognition Challenge)대회에서 매우 뛰어난 성능을 발휘하고 있으나[12], 분류하고자 하는 대상이 자동차, 말, 사람, 배, 꽃과 같이 특징이 매우

뚜렷한 데이터로 구성되어있다. 본 연구에서는 분류하고자 하는 대상이 모두 비슷한 유선형을 가지고 있으며, 분류하고자 하는 대상의 환경이 물 안으로 주위의 자연 환경에 따라 서로 다른 특징을 나타낸다.

따라서, 본 연구에서 외래어종 퇴치를 위한 효율적인 시스템 개발에 앞서 물 속에 있는 어류 이미지를 CNN으로 학습하여 어종을 분류하는 알고리즘을 제안하고자 한다. CNN 학습을 위한 원데이터(raw data)는 각 어종에 대해 직접 촬영한 영상을 사용하였으며, 어종 분류 성능을 높이기 위해 영상 이미지를 회전 및 좌우로 반전시켜 학습 데이터의 개수를 늘려 사용하였다[13]. 그리고 최대한 자연환경과 가까운 영상 이미지 구현을 위하여 하천이나 내수면에서 발생하는 녹조 성분의 이미지와 흙탕물의 이미지를 사용하여 물고기 이미지를 합성하고, 이를 학습 데이터 및 테스트 데이터로 사용하였다. CNN의 구조는 구조가 간단하고 높은 성능을 내는 AlexNet[14]과 최근에 많이 사용되는 VggNet(Vgg16, Vgg19)[15-17], GoogLeNet[18]으로 성능을 평가하여 외래어종 퇴치를 위한 어종 분류 시스템에 가장 적절한 네트워크를 선정하고자 한다.

II. 어종 분류를 위한 CNN과 데이터셋

CNN은 레이블이 있는 대량의 데이터를 사용하여 다양한 형태의 객체를 학습할 수 있다. 또한, 전송학습(transfer learning)을 통하여 학습된 네트워크를 새로운 인식 작업을 수행하여 네트워크를 재학습할 수 있는 장점 등이 있어 높은 정확성을 가지고 있다[15-19].

2.1. CNN

CNN은 LeCun 교수에 의해 개발된 알고리즘으로 동물의 시각처리 과정을 모방하여 패턴의 크기, 위치가 바뀌어도 인식할 수 있는 장점이 있는 이미지 인식 분야에서 가장 좋은 성능을 보이는 딥러닝 알고리즘으로[2-4], 국소수용영역(local receptive field), 가중치공유(share weights), 이단추출(sub-sampling) 방식으로 데이터의 특징을 추출하여 모델의 성능을 향상한다. 국소수용영역은 하위 계층의 노도가 상위계층의 모든 노드와 연결되어 있지 않고 지역적으로 일부의 노드에만 연결된 것을 의미하며, 가중치 공유는 공동으로 컨벌루션 필터




Fig. 1 CNN system[2-5]

(convolution filter)를 사용하여 패턴의 위치와 관계없이 특징점을 찾을 수 있는 역할을 한다. 또한, 이단추출은 풀링(pooling) 과정으로 특징점을 살리면서 파라미터의 개수를 줄여 연산시간을 단축하는 역할을 수행한다 [2~4].

CNN은 다른 네트워크와 마찬가지로 크게 입력층, 출력층과 두 계층 사이에 매우 많은 은닉층으로 구성되어 있다. 그림 1은 CNN의 일반적인 계층 구조를 표시하며 [2~4], 특징검출 계층과 분류 계층으로 나눌 수 있다. 특징검출 계층은 컨볼루션(convolution), ReLU(Rectified Linear Unit), 풀링 과정을 수행하며, 컨볼루션은 입력 이미지를 컨볼루션 필터를 사용하여 이미지의 특징을 활성화하는 역할을 한다. ReLU는 이미지 데이터들을 양수 값으로 유지하여 학습이 일어나지 않는 기울기 소실 현상(vanishing gradient)이 일어나지 않게 네트워크가 빠르고 학습하도록 한다. 또한, 풀링은 비선형 다운 샘플링을 수행함으로써 출력을 간소화하고 네트워크가 학습할 파라미터의 개수를 줄여준다[2~4]. 분류 계층은 CNN이 특징검출 계층을 지난 후 연결된 노드로 일반적으로 완전연결계층(FC: Fully Connected layer)로 구성되어 있으며, K 차원의 벡터를 출력한다. K는 네트워크가 예측할 수 있는 클래스의 개수를 말한다.

본 연구에서는 이러한 CNN 구조 중 구조가 간단하고 성능이 우수한 AlexNet과 최근에 많이 사용되는 VggNet(Vgg16, Vgg19), GoogLeNet을 전송학습(transfer learning)을 사용하여 학습한 후 성능을 평가하였다. 전송학습은 기존의 네트워크 출력을 없애고, 학습하고자 하는 물고기 종의 클래스 개수만큼 출력으로 연결하여 빠른 학습을 위해 사용하였다. 그리고 외래어종 퇴치 시스템에서 가장 중요한 어종 분류성과 어종 분류를 위한 수행 시간(execution time)이 중요한 결정요인이므로 4가지 네트워크의 성능평가 결과를 사용하여 어종 분류 시스템에 가장 적절한 네트워크를 선정하고자 한다.

2.2. 어종 분류를 위한 데이터세트

어종 분류를 위한 CNN 학습 및 테스트 데이터 수집은 인터넷 이미지나 동영상 이미지를 사용하여 확보하는 것은 많은 시간과 저작권 등의 문제가 있어 데이터 확보가 쉽지 않다. 그리고 직접 자연환경에서 물고기 영상을 촬영하여 데이터를 확보하는 것 또한 많은 시간과 특정 어종의 촬영이 매우 어려운 실정이다. 그러므로 본 연구에서는 실험실 환경에서 특정 어종을 확보하여 직접 어류의 동영상 이미지를 촬영하고, 촬영된 동영상을 기초로 어종의 이미지를 만들었다. 분류하고자 하는 어종 이미지는 생태계 교란 외래종인 큰입배스와 블루길을 포함하여 생태계 교란 외래종과 크기나 모양이 비슷하거나 우리나라의 하천 및 내수면에 주로 서식하는 잉어(common carp), 붕어(crucian carp), 메기(catfish), 쏘가리(mandarin fish), 누치(skin carp)로 데이터 세트를 구성하였다. 7종의 어류에 대하여 동영상 이미지로부터 5,000개의 이미지 데이터를 만들어 기본 데이터로 사용하였다.

CNN 학습의 정확도를 높이기 위해 이미지 데이터를 시계방향으로 5°, 10°, 15°, 20°씩 회전하고, 이를 좌우 반전시켜 1장의 이미지를 10장의 이미지로 확장하여 데이터세트 1을 구성하였다. 따라서 각 어종에 대한 이미지는 50,000(장/어종)으로 확장되었다. 그림 2는 촬영된 영상 이미지 중 쏘가리 이미지 1장을 10장으로 확장한 이미지의 예시이다.

또한, 최대한 자연환경과 가까운 영상 이미지 구현을 위하여 8장의 물속 자연환경 이미지를 선정하여 각 어종의 5,000장의 이미지와 합성하여 데이터세트 2를 만들었다. 8장의 물속 이미지는 내수면에서 발생하는 녹조 성분의 이미지와 흙탕물의 이미지를 사용하였다. 이미지의 합성은 원래의 어류 이미지와 8장의 물속 자연환경 이미지를 3:7, 4:6, 5:5, 6:4, 7:3으로 랜덤하게 선정하여 합성하여 각 어종당 5,000장의 이미지를 데이터세트 2로 구성하였다. 그림 3(a)은 물속 자연환경 이미지를 나타내며, 그림 3(b)는 합성된 어류 이미지를 표시하였다.




Fig. 2 data augmentation




Fig. 3 Images in the water and composite fish images
(a) Images of green algae and muddy water
(b) Composite fish images

합성된 어종 이미지는 자연의 물속에서 촬영된 영상과 매우 유사하게 만들어졌으며, 이는 실제 하천이나 내수면에서 촬영된 영상을 대체할 수 있을 것으로 생각된다. 표 1은 데이터세트 1과 데이터세트 2의 개수와 데이터 치수를 나타내었다.

Table. 1 The Dataset 1, Dataset 2

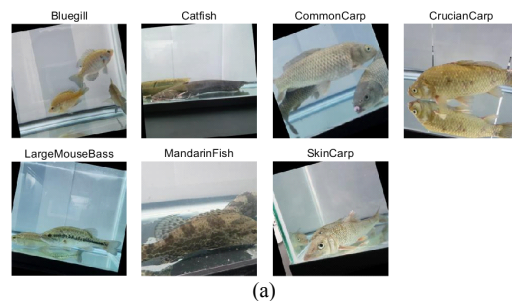
Fish species	Image size	Dataset 1	Dataset 2
Large Mouse Bass	227×227	50,000	5,000
Bluegill	227×227	50,000	5,000
Catfish	227×227	50,000	5,000
Common Carp	227×227	50,000	5,000
Crucian Carp	227×227	50,000	5,000
Mandarin Fish	227×227	50,000	5,000
Skin Fish	227×227	50,000	5,000

III. 실험 및 결과

실험에 앞서 물고기 분류를 위한 CNN은 구조가 간단하고 높은 성능을 내는 AlexNet, Vgg16, Vgg19, GoogLeNet를 사용하여 성능을 평가하였다. 각 네트워크는 Matlab[16~18]에서 제공하는 전송학습(transfer learning)을 사용하여 학습시간을 줄이고자 하였다. 이는 하천이나 내수면에서 외래 어종 분류 시스템에 CNN을 적용할 경우, 학습시간과 연산수행시간이 매우 중요한 요인으로 이를 고려하여 네트워크를 선정하였다. 각 네트워크의 최적화 방법은 Adam을 사용하였으며[20], 초기 학습률은 1.0×10^{-4} 으로 설정하고, 미니배치(mini batch)의 크기는 각 네트워크의 성능에 맞게 적절히 조정하였다. 하드웨어 장치로는 Intel i9-7900 3.30GHz CPU와 4개의 NVIDIA GeForce GTX1080Ti를 사용하였다.

3.1. 데이터세트 1에 의한 실험 결과 및 분석

학습(learning)과 테스트(test)를 위한 데이터세트 1은 어종 당 50,000장의 이미지로 구성되어있으며, 각 어종 당 데이터의 20%는 테스트 데이터로 선정하였으며, 나머지 데이터 중 70%와 30%인 56%와 24%는 학습과 확인(validation)을 위한 데이터로 분류하였다. 그림 4는 네트워크 중 대표적인 AlexNet의 학습 데이터세트의 예와 학습 진행 과정을 보여준다. 미니배치(mini batch) 치수가 1024이고 전체 학습횟수는 900번이므로 4.71번의 epoch을 수행하였다. 학습 후 CNN의 성능평가는 테스트 데이터 10,000(장/어종)에 대하여 99.97%로 매우 높은 정확도를 나타내었다. 이는 CNN이 수조 속의 실험실 환경에서 자연환경에서 촬영된 이미지와 비교하여 분류하고자 하는 물고기들의 특징을 더욱 잘 추출함을 알 수 있다.



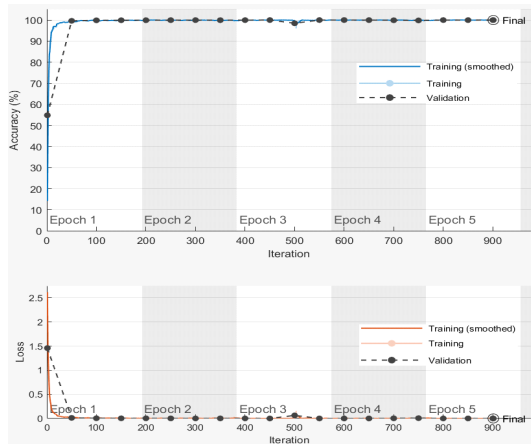


Fig. 4 Training Set and Training Progress (a) Training Set 1 of AlexNet (b) Training Progress of AlexNet

표 2는 4가지 네트워크의 미니배치, 학습횟수, 1개 이미지에 대한 수행시간 및 성능 등을 표시하였다. 학습된 CNNs의 성능은 모두 99.9% 이상의 높은 분류성능을 나타내었으며, 이는 학습 및 테스트 데이터가 같은 수조 환경에서 촬영되어 어종 분류성능이 매우 뛰어남을 알 수 있다. 수조와 같은 실험실 환경은 분류하고자 하는 물고기들의 특징이 잘 추출됨을 알 수 있다. 따라서 자연환경에서 촬영된 물고기 영상에 대해 고려가 필요하다. 그리고 1개 이미지에 대한 수행시간과 학습시간은 CNNs 중 AlexNet이 Vgg19에 비교하여 약 8배 정도 빠름을 확인하였다. 이는 다른 네트워크와 비교하여 네트워크가 깊지 않아 수행시간이 짧으며, 분류하고자 하는 어종의 수가 적어 작은 크기의 네트워크로도 충분히 잘 학습됨을 알 수 있다. 특히, 수행시간은 외래종 퇴치를 위한 어종 분류 시스템 개발에 가장 중요한 요인이다.

Table. 2 The Classification Performance of CNNs using Test Data in Dataset 1

CNN	AlexNet	GoogLeNet	Vgg16	Vgg19
Mini batch	1024	512	200	200
No. of training	900	600	3650	10
Execution time for one image	$1.69e^{-3}$	$6.26e^{-3}$	$1.21e^{-2}$	$1.35e^{-2}$
Test accuracy	99.97%	99.98%	99.98%	99.99%

데이터세트 1에 의해 학습된 CNNs의 테스트 이미지에 대한 분류성능은 표 2와 같이 모두가 만족할 만한 성

능을 보이나, 자연환경 영상이 포함된 데이터세트 2의 테스트 이미지에 대한 분류성능은 매우 낮은 성능 결과를 보여주었다. 표 3은 데이터세트 1에 의해 학습된 네트워크에 데이터세트 2의 테스트 이미지에 대한 분류성능을 나타낸다. AlexNet의 분류성능이 55.53%로 나타났으며, Vgg19의 분류성능이 80.2%로 가장 높은 결과를 나타내었다. 네트워크가 깊어짐에 따라 CNNs의 분류성능이 높아짐을 확인하였다. 이는 가장 깊이가 얇은 AlexNet이 데이터세트 1의 수조 속의 실험실 환경데이터에 과적합(over fitting)된 것으로 생각된다. 또한, 학습된 CNNs이 자연환경에 가까운 이미지가 포함된 학습 데이터가 없어 어종을 구분하는 것이 어렵다는 것을 알 수 있다. 따라서 CNN의 학습을 자연환경 이미지가 포함된 데이터세트 2에 의해 학습하여 테스트하는 것이 더 정확한 어종 분류 시스템을 설계하는 일차적인 과제이다.

Table. 3 The Classification Performance of CNNs learned by Dataset 1 using Test Data in Dataset 2

CNN	AlexNet	GoogLeNet	Vgg16	Vgg19
Test accuracy	55.53%	78.0%	73.1%	80.2%

3.2. 데이터세트 2에 의한 실험 결과 및 분석

앞서 설계된 CNNs은 데이터세트 1에 대해 어종 분류성능이 뛰어남을 확인하였다. 그러므로 어류의 원본 이미지만으로도 어류의 특징점을 충분히 잘 표현하는 것으로 간주하여 회전이나 반전 등의 데이터 확장 없이 데이터세트 2를 구성하였다. 데이터세트 2는 그림 3(a)와 같은 하천이나 내수면에서 발생하는 녹조 성분의 이미지와 흙탕물의 이미지 8장을 랜덤하게 일정 비율(7:3, 6:4, 5:5, 4:6, 3:7)로 원본 어류 이미지와 합성하여 각 어종당 5,000장의 이미지로 구성하였다. 그리고 학습과 테스트를 위해 데이터세트 1과 같이 각 어종당 데이터의 20%는 테스트 데이터로 선정하고, 데이터의 56%와 24%는 학습과 확인을 위한 데이터로 분류하였다.

학습 데이터 예는 앞의 그림 3(b)와 같으며, 그림 5는 AlexNet의 어종 분류결과를 나타내었다. 블루길의 경우 1,000장의 테스트 이미지에 대하여 100% 완벽히 분류하였으나, 붕어와 잉어의 이미지가 매우 유사하여 13장의 붕어 이미지를 잉어 이미지로 잘못 분류하여 붕어 이미지의 분류성능은 98.3%로 나타났다. 그러나 전체 다

른 종에 대해서도 99.1% 이상 분류하였음을 알 수 있다. 평균적으로 모든 어종에 대하여 99.5% 이상 분류 정확성을 나타내었다.

그림 6은 잉어와 쏘가리 이미지를 정확히 분류한 예를 표시하였다. 잉어의 이미지가 붕어와 매우 유사함에도 불구하고 정확히 분류되었음을 나타낸다. 그림 7은 큰입배스와 메기를 붕어로 잘못 분류한 예를 표시하였다. 특히 그림 6(c)의 메기 이미지의 경우, 어류 전문가 들조차도 메기 이미지로 정확히 인지하기 어렵다.

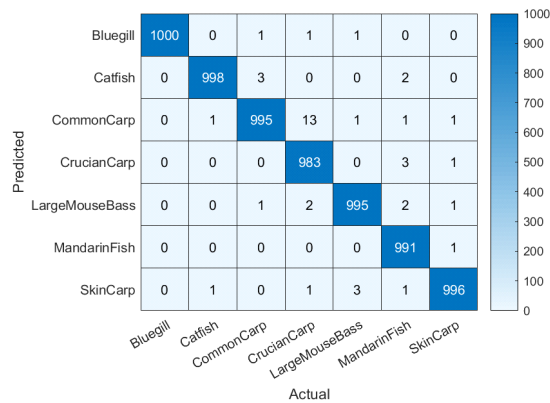


Fig. 5 Classification Result using Dataset 2 of AlexNet

CNN에 대한 분류성능 비교는 표 4와 같다. 데이터세트 2에 의한 CNN의 분류성능은 모두 99.5% 이상을 기록하였으며, 데이터세트 1에 의한 분류성능에 비교하여 조금 떨어짐을 알 수 있다.

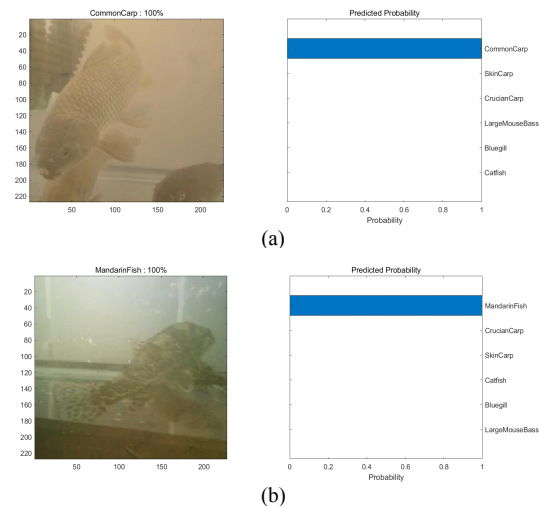


Fig. 6 Correct Predicted Results

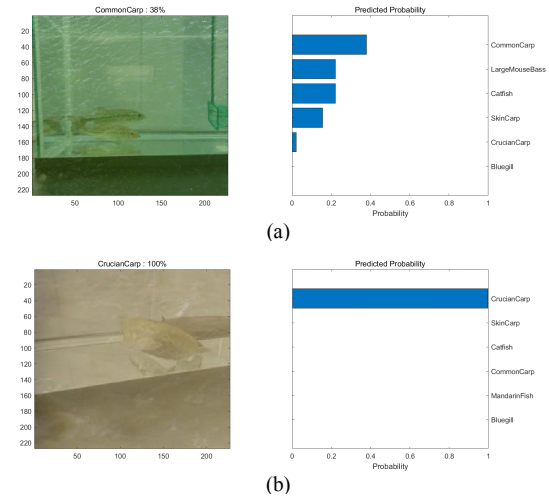


Fig. 7 Non Correct Predicted Results

그러나 분류성능이 모두 99.5% 이상을 나타냄으로 어종 분류 시스템에서 적용하기에는 어려움이 없을 것으로 생각된다. 이는 각각의 CNN이 자연환경과 유사한 이미지를 학습함으로써 테스트 분류성능이 높아졌음을 알 수 있다. 또한, 분류하는 어종의 종류가 많지 않아 네트워크의 복잡도와 관계없이 모두 다 좋은 성능을 나타내었다. 그리고 하나의 이미지에 대한 수행시간과 학습 시간은 AlexNet이 가장 짧았으며, 네트워크가 가장 깊은 Vgg19가 가장 긴 시간을 소모하였다. 따라서 CNN 중 가장 구조가 단순한 AlexNet의 사용으로도 외래어종 퇴치를 위한 시스템 개발에 가장 적합한 구조임을 확인하였다.

Table. 4 The Classification Performance of CNNs using Test Data in Dataset 2

CNN	AlexNet	GoogLeNet	Vgg16	Vgg19
Mini batch	1024	512	512	200
No. of training	450	650	600	950
Execution time for one image	$1.26e^{-3}$	$6.17e^{-3}$	$1.42e^{-2}$	$1.50e^{-2}$
Test accuracy	99.5%	99.6%	99.8%	99.6%

IV. 결 론

본 연구에서 외래어종 퇴치를 위한 시스템 개발에 앞서 물 안에 있는 어류 이미지를 CNN으로 학습하여 어종을 분류하는 알고리즘을 제안하고자 한다. CNN 학습을 위한 원데이터는 각 어종에 대해 직접 촬영한 영상을 사용하였으며, 어종 분류성능을 높이기 위해 영상 이미지의 개수를 늘린 데이터세트 1과 최대한 자연환경과 가까운 영상 이미지 구현을 위한 데이터세트 2를 구성하여 학습 및 테스트 데이터로 사용하였다.

4가지 CNN의 분류성능은 데이터세트 1에 대해 99.97%, 데이터세트 2에 대해 99.5%이상을 나타내었으며, 특히 데이터세트 2를 사용하여 학습한 CNN이 자연환경과 유사한 이미지에 대해서도 학습할 수 있음을 확인하였다. 그리고 4가지 CNN 중 AlexNet이 성능에서도 만족스러운 결과를 도출하였으며, 수행시간과 학습시간 역시 가장 짧아 외래어종 퇴치를 위한 시스템 개발에 가장 적합한 구조임을 확인하였다.

ACKNOWLEDGEMENT

This paper was supported by the research project for the biodiversity threat biological control technology development project of the Ministry of Environment in 2018.

REFERENCES

- [1] Korea Institute for International Economic Policy. 10th Session of the Conference of the Parties to the Convention on Biological Diversity : Nagoya Protocol [Internet]. Available: http://www.kiep.go.kr/sub/view.do?bbsId=global_econo&nttId=185515.
- [2] Y. Le Cun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.
- [3] Y. Bengio, "Learning deep architectures for AI," *Foundations and Trends in Machine Learning*, vol. 2, no. 1, pp. 1-127, Feb. 2009.
- [4] G. E. Hinton, S. Osindero, and Y. Teh, "A fast learning algorithm for deep belief nets," *Neural Computation*, vol. 18, no. 7, pp. 1527-1554, Jul. 2006.
- [5] S. I. Hassan, L. Dang, S. H. Im, K. B. Min, J. Y. Nam, and H. J. Moon, "Damage Detection and Classification System for Sewer Inspection using Convolutional Neural Networks based on Deep Learning," *Journal of the Korea Institute of Information and Communication Engineering*, vol. 22, no. 3, pp. 451-457, Mar. 2018.
- [6] J. H. Kim, D. S. Choi, H. S. Lee, and J. W. Lee, "Target Classification of Active Sonar Returns based on Convolutional Neural Network," *Journal of the Korea Institute of Information and Communication Engineering*, vol. 21 no. 10, pp. 1909-1916, Oct. 2017.
- [7] G. Chen, P. Sun, and Y. Shang, "Automatic Fish Classification System Using Deep Learning," *Tools with Artificial Intelligence(ICTAI), 2017 IEEE 29th International Conference on*. IEEE, pp. 24-29, 2017.
- [8] V. A. Sindagi, and V. M. Patel, "A Survey of Recent Advances in CNN-based Single Image Crowd Counting and Density Estimation," *Pattern Recognition Letters*, vol. 107, no. 1, pp. 3-16, May 2018.
- [9] M. Sarigül, and M. Avci, "Comparison of Different Deep Structures for Fish Classification," *International Journal of Computer Theory and Engineering*, vol. 9, no. 5, Oct. 2017.
- [10] H. Qin, X. Li, J. Liang, Y. Peng, and C. Zhang, "DeepFish: Accurate under water live fish recognition with a deep architecture," *Neurocomputing*, vol. 187 no. 26, pp. 49-58, Apr. 2016.
- [11] A. Salman, A. Jalal, F. S., A. Mian, M. Shortis, J. Seager, and E. Harvey, "Fish species classification in unconstrained underwater environments based on deep learning," *LIMNOLOGY and OCEANOGRAPHY: METHODS*, Association for the Sciences of Limnology and Oceanography, vol. 14, no. 9, pp. 570-585, Sep. 2016.
- [12] Stanford Vision Lab, Stanford University, Princeton University, Large Scale Visual Recognition Challenge, [Internet]. Available: www.image-net.org.
- [13] I. K. Choi, H. E. Ahn, and J. S. Yoo, "Facial Expression Classification Using Deep Convolutional Neural Network," *Journal of Electrical Engineering & Technology*, vol. 13, no. 1, pp. 485-492, Jan. 2018.
- [14] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Advances in neural information processing systems 25(NIPS2012)*, pp. 1097-1105, 2012.
- [15] K. Simonyan and A. Zisserman. (2015, May). Very deep convolutional networks for large-scale image recognition. *3rd International Conference on Learning Representations*.

- [Internet]. Available: <http://arxiv.org/abs/1409.1556>.
- [16] MathWorks, Pretrained VGG-16 convolutional neural network, [Internet]. Available: <https://kr.mathworks.com/help/deeplearning/ref/vgg16.html>.
- [17] MathWorks, Pretrained VGG-19 convolutional neural network, [Internet]. Available: <https://kr.mathworks.com/help/deeplearning/ref/vgg19.html>.
- [18] MathWorks, Pretrained GoogLeNet convolutional neural network, [Internet]. Available: <https://kr.mathworks.com/help/deeplearning/ref/googlenet.html>.
- [19] Y. Bengio, "Deep Learning of Representations for Unsupervised and Transfer Learning," *Proceedings of Machine Learning Research, Volume 27: Proceedings of ICML Workshop on Unsupervised and Transfer Learning*, Washington:WA, pp. 17-37, Jul. 2012.
- [20] J. Ba, and D. P. Kingma. (2015, May). Adam: A Method for Stochastic Optimization. *3rd International Conference on Learning Representations*. [Internet]. Available: <http://arxiv.org/abs/1412.6980>.



박진현(Jin-Hyun Park)

1992년 2월 부산대학교 전기공학과 공학사
 1994년 2월 부산대학교 대학원 전기공학과 공학석사
 1997년 2월 부산대학교 대학원 전기공학과 공학박사
 1997년 3월 ~ 1999년 2월 부산정보대학 전기전자계열 전임강사
 2006년 7월 ~ 2007년 8월 Dept. of System Engineering, Arkansas Univ. at Little Rock, Visiting Scholar
 1999년 3월 ~ 현재 경남과학기술대학교 메카트로닉스공학과 교수
 ※ 관심분야: 지능제어, 최적제어, 로봇틱스, 딥러닝



황광복(Keang-Bok Hwang)

2003년 2월 경남과학기술대학교 메카트로닉스공학과 공학사
 2006년 8월 경상대학교 대학원 전기전자공학과 공학석사
 2014년 2월 경남과학기술대학교 대학원 컴퓨터 메카트로닉스공학과 박사수료
 2006년 9월 ~ 2011년 3월 로보주식회사 부장
 2011년 4월 ~ 현재 KB로보테크 대표
 ※ 관심분야: 지능제어, 로봇틱스, 제어계측



박희문(Hee-Mun Park)

2006년 2월 경남과학기술대학교 메카트로닉스공학과 공학사
 2014년 2월 경남과학기술대학교 산업대학원 융합기술공학 공학석사
 2006년 4월 ~ 2011년 12월 THE SYSTEM
 2014년 9월 ~ 2017년 9월 비원이미지 연구소
 2017년 9월 ~ 현재 BAT KOREA
 ※ 관심분야: 지능제어, 로봇틱스, 제어계측



최영규(Young-Kiu Choi)

1980년 2월 서울대학교 전기공학과 공학사
 1982년 2월 KAIST 전기 및 전자공학과 공학석사
 1987년 2월 KAIST 전기 및 전자공학과 공학박사
 1986년 ~ 현재 부산대학교 전기공학과 교수
 ※ 관심분야: 로봇제어, 지능제어, 신경회로망, 딥러닝